Laporan Analisis Word2vec Skip-Gram menggunakan library Gensim

1. min count digunakan untuk mengabaikan semua kata dengan frekuensi total lebih rendah dari apa yang kita setting. Setting yang digunakan pada experiment kali ini adalah min_count = 1 dan min_count=5. Jadi apabila kata kata yang jarang muncul maka akan dihapus sebelum pelatihan dilakukan.

```
[5] import gensim.models
                                                                                                                                                                        [22] import gensim.models
        sentences = MvCorpus()
         model = gensim.models.Word2Vec(sentences=sentences,size = 100, min_count=1)
                                                                                                                                                                                  model = gensim.models.Word2Vec(sentences=sentences,size = 100, min_count=5)
                                                                                                                                                                                 2020-10-14 13:28:04,675 : INFO : collecting all words and their counts 2020-10-14 13:28:04,677 : INFO : PROGRESS: at sentence #0, processed 0 2020-10-14 13:28:04,713 : INFO : collected 3812 word types from a corp
 2020-10-14 12:57:13,850 : INFO : collecting all words and their counts
       2020-10-14 12:57:13,850 : INFO : collecting all words and their counts 2020-10-14 12:57:13,855 : INFO : PROGRESS: at sentence #θ, processed θ words, keeping θ w 2020-10-14 12:57:13,883 : INFO : collected 3812 word types from a corpus of 24333 raw word 2020-10-14 12:57:13,987 : INFO : boading a fresh vocabulary 2020-10-14 12:57:13,989 : INFO : effective_min_count-1 retains 3812 unique words (100% of 2020-10-14 12:57:13,940 : INFO : effective_min_count-1 leaves 24333 word corpus (100% of 2020-10-14 12:57:13,954 : INFO : semple=0.001 downsamples 54 most-common words 2020-10-14 12:57:13,955 : INFO : sample=0.001 downsamples 55 word corpus (85.3% o 2020-10-14 12:57:13,956 : INFO : setimated required memory for 3812 twords and 100 dimensi 2020-10-14 12:57:13,969 : INFO : resetting layer weights 2020-10-14 12:57:13,960 : INFO : resetting layer weights 2020-10-14 12:57:14,693 : INFO : training model with 3 workers on 3812 vocabulary and 100 2020-10-14 12:57:14,693 : INFO : training model with 3 workers on 3812 vocabulary and 100 2020-10-14 12:57:14,693 : INFO : where thread finished; awaiting finish of 2 more thread finished; awaiting finished; awaitin
                                                                                                                                                                                                                                    PROGRESS: at sentence #θ, processed θ words, keeping θ word types collected 3812 word types from a corpus of 24333 raw words and 312 sentences Loading a fresh vocabulary
                                                                                                                                                                                                                                   Loading a fresh vocabulary effective min count-s retains 899 unique words (23% of original 3812, drops 2913) effective min count-s leaves 19507 word corpus (88% of original 24333, drops 4826) deleting the raw counts dictionary of 3812 items sample=0.081 downsamples 67 most-common words
                                                                                                                                                                                 2020-10-14 13:28:04,729
                                                                                                                                                                                 2020-10-14 13:28:04,729
                                                                                                                                                                                                                                   downsampling leaves estimated 15295 word corpus (78.4% of prior 19507) estimated required memory for 899 words and 100 dimensions: 1168700 bytes
                                                                                                                                                                                 2020-10-14 13:28:04,730
                                                                                                                                                                                                                         INFO
                                                                                                                                                                                 2020-10-14 13:28:04,733
                                                                                                                                                                                 2020-10-14 13:28:04,733
2020-10-14 13:28:04,907
                                                                                                                                                                                                                         INFO: resetting layer weights
INFO: training model with 3 workers on 899 vocabulary and 100 features, using sg-0 hs-0 s
                                                                                                                                                                                2020-10-14 13:28:04,947: INFO: worker thread finished; awaiting finish of 2 more threads 2020-10-14 13:28:04,953: INFO: worker thread finished; awaiting finish of 1 more threads
        2020-10-14 12:57:14,742 : INFO : worker thread finished; awaiting finish of 2 mor
  vec_positif = model.wv['covid']
                                                                                                                                                                                vec_positif = model.wv['covid']
          print(vec_positif)
                                                                                                                                                                                        print(vec_positif)

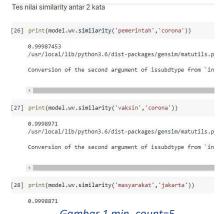
    □ 0.28922394   0.31365943  -0.45084956   0.15036564  -0.15155439  -0.3200764

              0.58655334 0.06447885 -0.5772228
                                                                                  0.16196154 -0.20199992
                                                                                                                              9 86897516
                                                                                                                                                                                             0.5495379
                                                                                                                                                                                                                    0.04600057 -0.9030283
                                                                                                                                                                                                                                                                   0.263558
                                                                                                                                                                                                                                                                                         -0.16316102
             -0.5686483
                                    0.22410831 -0.15071024
                                                                                  0.20845893 -0.51350784
                                                                                                                              0.6308682
                                                                                                                                                                                           -0.67125636
                                                                                                                                                                                                                   0.03081998 -0.1683466
                                                                                                                                                                                                                                                                   0.10639236 -0.62544584
                                                                                                                                                                                                                                                                                                                 0.7386577
             0.2971287
                                 -0.67737806
                                                          0.0934433
                                                                                 0.24973103 -0.592605
                                                          -0.34809873
                                                                                 -0.46496406 -0.21925227 -0.08522454
                                                                                                                                                                                            0.22070138 -0.08169428 -0.40921476 -0.58205694 -0.34174064 -0.26027617
             0.20308742 -0.16323332 -0.03922995
                                                                                -0.549131
                                                                                                        0.1826409
                                                                                                                             -0.669974
                                                                                                                                                                                            0.06529167
                                                                                                                                                                                                                    -0.44196263
                                                                                                                                                                                                                                           0.03659781
                                                                                                                                                                                                                                                                  -0.63192016
                                                                                                                                                                                                                                                                                          0.17569384
              0.2658744
                                   -0.00461986
                                                          -0.5255522
                                                                                  0.10039018
                                                                                                        0.12185021
                                                                                                                                                                                            9.25427294
                                                                                                                                                                                                                   0.20746177 -0.5014332
                                                                                                                                                                                                                                                                   0.04405181
                                                                                                                                                                                                                                                                                          0.05814064 -0.34767535
              0.09170914 0.5094627
                                                         -0.1694563
                                                                                  0.3895452
                                                                                                        0.05969986
                                                                                                                              0.53724945
                                                                                                                                                                                                                                                                                         -0.03442214
                                                                                                                                                                                            0.13279924
                                                                                                                                                                                                                   0.5230738
                                                                                                                                                                                                                                          -0.24471463
                                                                                                                                                                                                                                                                   0.47055876
                                   0.2810959
                                                           0.10661396
                                                                                  0.0132287
                                                                                                        -0.5016978
                                                                                                                                                                                           -0.18592583
                                                                                                                                                                                                                   0.07998727
                                                                                                                                                                                                                                          0.2648435
                                                                                                                                                                                                                                                                   0.13162348 -0.57263315
                                                                                                                                                                                                                                                                                                                -0.49423268
             -0.2871117
                                  -0.28477994
                                                           0.6309997
                                                                                 0.0262686
                                                                                                        0.6223264
                                                                                                                               0.31715554
                                                                                                                                                                                           -0.31795162
                                                                                                                                                                                                                   -0.17445585
                                                                                                                                                                                                                                           0.8001803
                                                                                                                                                                                                                                                                  -0.14122763
                                                                                                                                                                                                                                                                                          0.48523104
                                                                                                                                                                                                                                                                                                                  0.3291617
             -0.48327747 0.13773248
                                                          0.00605237
                                                                                -0.18371572 -0.20005222
                                                                                                                              9.07285272
                                                                                                                                                                                           -0 72325754
                                                                                                                                                                                                                   0.05060219
                                                                                                                                                                                                                                           0.34463784 -0.11068175 -0.3578359
                                                                                                       0.11801158
              0.12181243
                                   0.03708332
                                                           0.76129514
                                                                                 0.7811379
                                                                                                                                                                                                                   0.13669431
                                                                                                                                                                                                                                          0.8671354
                                                                                                                                                                                                                                                                   0.8354314
                                                                                                                                                                                            0.18872626
                                                                                                                                                                                                                                                                                          0.19900392
             0.13796629 -0.10718533
                                                          -0.00824278 -0.17290768 -0.06111373
                                                                                                                              0.04883865
                                                                                                                                                                                            0.30316603 -0.1131751
                                                                                                                                                                                                                                          -0.02332059
                                                                                                                                                                                                                                                                   0.23904848 -0.04977218
                                                                                                                                                                                                                                                                                                                 0.03137538
                                                           0.10689959
                                                                                 0.02378752
                                                                                                       0.11877958
                                                                                                                                                                                                                   0.09483157
                                                                                                                                                                                                                                                                   0.06944838 -0.08434725
                                                                                                                                                                                           -0.5032374
                                                                                                                                                                                                                                           0.29900625
                                                                                                                                                                                                                                                                                                                 0.5731952
             -0.3399043
                                    0.4743451
                                                         -0.5134933
                                                                                 0.01867717 -0.5406575
                                                                                                                               0.33988017
                                                                                                                                                                                                                   0.36629736 -0.9495105
                                                                                                                                                                                                                                                                   0.3790426
                                                          -0.45058516 -0.18209127 -0.07521641
                                                                                                                                                                                                                                                                                         -0.15352759 0.501799
                                                                                                                                                                                            0.20094869 -0.7154701
                                                                                                                                                                                                                                          -0.5788972
                                                                                                                                                                                                                                                                   0.251251
              0.09365943 -0.18236434 0.14887536 0.2909882 ]
                                                                                                                                                                                           -0.00680109 -0.14573407 -0.08576518
```

2. Hitung nilai similarity antar kata dengan memilih 3 pasang kata yang Anda perkirakan nilai similaritynya.

3 pasang kata yang digunakan yaitu 'pemerintah' dengan 'corona', 'vaksin' dengan 'corona', dan 'masyarakat' dengan 'jakarta'. Akurasi yang didapatkan dari min_count=5 memiliki nilai similarity yang lebih besar dari min_count = 1. Karena jika kita melakukan setting dimana min_count = 5 maka kata-kata yang kemunculannya kurang dari 5 tidak akan disimpan pada konteks data. Sehingga akurasi yang dihasilkan akan lebih besar dari min_count =1.





Gambar 1 min_count=5

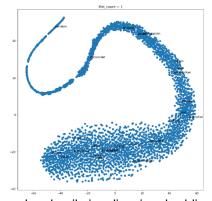
3. Cari top-5 kata yang similar dengan sebuah kata tertentu, amati hasilnya, berikan analisis terhadap hasil yang Anda peroleh. Bandingkan hasil

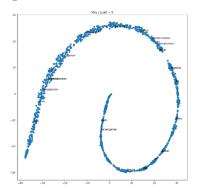


Gambar 3. Min_count=5

Berdasarkan hasil akurasi min_count = 5 nilai similaritynya lebih besar dari min_count = 1 walaupun perbedanyaannya sangat kecil. Dan juga terdapat perbedaan kata yang similar antara min_count = 1 dengan min_count = 5 ,karena jika kita setting min_count = 5, maka kata-kata yang muncul kurang dari 5 akan dihilangkan dari konteks data. Sehingga hasil similarity dari sebuah kata juga akan berbeda.

4. Lakukan visualisasi embedding dengan matplotlib





Berdasarkan hasil visualisasi embedding dengan matplotlib visualisasi dari min_count = 1 data data lebih banyak yang berkelompok/cluster dibandingkan pada min_count = 1. Karena min_count = 1 menyebabkan semua data bisa menjadi data latih sedangkan min_count 5 data yang kemunculannya kurang dari 5 akan dihapus dari konteks data . Sehingga kata pada min_count = 1 lebih banyak dari pada kata pada min_count = 5.